

Predição e Classificação de Risco de Burnout

Pipeline de Aprendizado de Máquina Aplicado à Gestão de Saúde Ocupacional

Breno Porto Pinheiro do Prado, RA 185196

Guilherme Bento Ramos, RA 185226

Universidade Federal de São Paulo — UNIFESP

São José dos Campos

2026

Abstract—O esgotamento profissional (*burnout*) configura crescente desafio de saúde ocupacional com impactos documentados sobre produtividade, rotatividade e bem-estar. Este trabalho propõe um *pipeline* modular de aprendizado de máquina para predição e classificação de risco de *burnout*, alinhado aos Objetivos de Desenvolvimento Sustentável ODS 3, ODS 8 e ODS 10 da ONU. A partir do *dataset* “Remote Work Health Impact Survey 2025” (Kaggle, 3.157 registros, coletado em junho de 2025), o sistema percorre cinco etapas: Análise exploratória, pré-processamento sem vazamento de dados, treinamento comparativo de Regressão Linear, Random Forest e XGBoost, avaliação com K-Fold e análise de equidade, e função de *scoring* individual. O alvo `Burnout_Level` (categórico ordinal: Low, Medium, High) é tratado como regressão ordinal, com *score* normalizado para $[0, 1]$. Os três modelos alcançaram desempenho similar sobre os dados de survey auto-reportados ($R^2 \approx 0,04$; $MAE \approx 0,64$ na escala ordinal 0–2). A *feature* mais influente na Regressão Linear foi `Work_Arrangement` ($w = +0,364$), enquanto o Random Forest distribuiu importância entre `Age` (16,5%), `Hours_Per_Week` (15,3%) e `Job_Role` (13,4%). Achado relevante da EDA: trabalhadores em regime *remote* apresentam *burnout* médio superior ao regime presencial (1,33 vs. 0,96 na escala ordinal).

Index Terms—burnout, aprendizado de máquina, regressão, XGBoost, Random Forest, saúde ocupacional, *scoring* de risco, ODS

I. INTRODUÇÃO

O esgotamento profissional (*burnout*) é um fenômeno psicossocial de impacto crescente nas organizações contemporâneas. Definido por Maslach e Jackson [1] como síndrome de exaustão emocional, despersonalização e redução do senso de realização pessoal, o *burnout* foi reconhecido em 2019 pela Organização Mundial da Saúde (OMS) como fenômeno ocupacional na Classificação Internacional de Doenças (CID-11). Pesquisas de longo prazo associam o fenômeno a absenteísmo elevado, intenção de abandono de cargo, doenças cardiovasculares e transtornos mentais [2].

A relevância do tema transcende o âmbito individual: o esgotamento de trabalhadores impõe custos sistêmicos à saúde pública e à economia. Nesse sentido, este trabalho está alinhado a três Objetivos de Desenvolvimento Sustentável da ONU [3]:

- **ODS 3 — Saúde e Bem-Estar:** promoção de ambientes de trabalho saudáveis e redução de agravos à saúde mental;
- **ODS 8 — Trabalho Decente e Crescimento Econômico:** proteção dos direitos trabalhistas e condições de trabalho seguras e saudáveis para todos;

- **ODS 10 — Redução das Desigualdades:** identificação de subgrupos com maior exposição ao risco para permitir intervenções equitativas.

A detecção precoce do risco de *burnout* é substancialmente mais eficaz do que estratégias reativas. Técnicas de aprendizado de máquina permitem identificar padrões de risco a partir de dados de recursos humanos já coletados pelas organizações — como carga de trabalho alocada, nível de fadiga mental e tempo de empresa — sem a necessidade de instrumentos psicométricos adicionais.

É fundamental, contudo, delimitar o escopo do sistema: o *pipeline* proposto é uma **ferramenta de triagem estatística**, não um instrumento de diagnóstico clínico. O escore produzido indica a *probabilidade estimada* de esgotamento com base em padrões históricos observados nos dados de treinamento. A interpretação do resultado e qualquer decisão sobre intervenção devem envolver profissionais de saúde habilitados (psicólogo, médico do trabalho) e a equipe de RH.

Este trabalho constrói um *pipeline* modular, com código aberto e reproduzível (SEED = 42), que compara três modelos de regressão em complexidade crescente, avalia equidade preditiva por subgrupos e entrega um script interativo de *scoring* individual em terminal. O documento está organizado da seguinte forma: a Seção II descreve o *dataset*; a Seção III apresenta a arquitetura do *pipeline*; as Seções IV–IX detalham cada etapa; a Seção VII apresenta os resultados; a Seção VIII discute equidade; e as Seções X e XI encerram com limitações e conclusão.

II. DATASET

A. Descrição

O *dataset* “Remote Work Health Impact Survey 2025” [8], disponível publicamente na plataforma Kaggle, reúne respostas de um survey global aplicado em junho de 2025 a trabalhadores em regimes remoto, híbrido e presencial no período pós-pandemia. O conjunto possui **3.157 registros** e **14 colunas** (Tabela I). A variável alvo, `Burnout_Level`, é categórica ordinal com três categorias: Low, Medium e High, que foram convertidas para representação numérica (0, 1 e 2) tratada como regressão ordinal. A distribuição do alvo é: Low = 23,6%, Medium = 43,3%, High = 33,1%. Nenhuma linha apresenta alvo ausente.

As únicas colunas com valores ausentes são `Mental_Health_Status` (799 registros, 25,3%) e

TABLE I
VARIÁVEIS DO DATASET “REMOTE WORK HEALTH IMPACT SURVEY 2025”.

Coluna	Tipo	Faixa / Valores	Papel
Survey_Date	Data	Junho/2025	Descartada
Age	Num. inteira	22–65	Feature
Gender	Categ. nominal	Female, Male, Non-binary, ...	Feature
Region	Categ. nominal	6 regiões globais	Feature
Industry	Categ. nominal	9 setores	Feature
Job_Role	Categ. nominal	20 cargos	Feature
Work_Arrangement	Categ. ordinal	Onsite, Hybrid, Remote	Feature
Hours_Per_Week	Num. inteira	35–65	Feature
Mental_Health_Status	Categ. nominal	6 condições + None	Feature
Burnout_Level	Categ. ordinal	Low, Medium, High	Alvo
Work_Life_Balance_Score	Num. ordinal	1–5	Feature
Physical_Health_Issues	Texto multi-label	var. ou ausente	→ has_physical_issue
Social_Isolation_Score	Num. ordinal	1–5	Feature
Salary_Range	Categ. ordinal	\$40K–\$120K+	Feature

Fonte: elaborado pelos autores.

Physical_Health_Issues (280 registros, 8,9%). O alvo Burnout_Level não apresenta valores ausentes.

B. Natureza e Contexto do Dataset

O dataset “Remote Work Health Impact Survey 2025” [8] foi coletado em junho de 2025 e representa uma amostra global de trabalhadores em regime remoto, híbrido e presencial no período pós-pandemia. Os dados são auto-reportados por meio de survey anônimo, cobrindo 3.157 respondentes de múltiplas regiões, setores e faixas etárias. O uso de dados reais de survey — em contraste com datasets sintéticos — confere maior validade ecológica às conclusões, embora introduza vies de resposta e seleção amostral inerentes à metodologia de survey.

Esse conjunto é apropriado para este trabalho porque possui variável-alvo clara, atributos plausíveis, acesso público e licença aberta. O impacto das limitações é discutido na Seção X.

III. ARQUITETURA DO PIPELINE

O sistema é estruturado como um *pipeline* sequencial de cinco etapas, cada uma implementada em um módulo Python dedicado (Tabela II). A modularidade garante que cada componente possa ser executado, testado e atualizado de forma independente.

O fluxo de dados segue estritamente a ordem das etapas: a EDA informa as decisões de pré-processamento; o pré-processamento produz os dados limpos e os artefatos de transformação (`imputer.pkl`, `scaler.pkl`); o treinamento produz os modelos serializados (`.pkl`); a avaliação consome todos os artefatos anteriores para medir o desempenho; e o *scoring* reutiliza os artefatos de transformação e o melhor modelo para previsões em tempo real.

A reprodutibilidade é garantida por dois parâmetros globais definidos em `src/config.py` e utilizados em todos os componentes:

- **SEED=42** — semente fixa aplicada na divisão treino/teste (`train_test_split`), no Random Forest (`random_state`), no XGBoost e no K-Fold. Qualquer execução do *pipeline*

com os mesmos dados produz exatamente os mesmos resultados.

IV. ETAPA 1 — ANÁLISE EXPLORATÓRIA DOS DADOS

A. Distribuição da variável alvo

O Burnout_Level é distribuído em três categorias: **Low** (23,6%), **Medium** (43,3%) e **High** (33,1%) (Figura 1). A maior concentração em “Medium” indica que a maioria dos respondentes auto-relata nível moderado de esgotamento.

B. Correlações e achado principal

O mapa de calor de correlação de Pearson (Figura 2) mostra correlações fracas entre as variáveis numéricas e o alvo — esperado em dados de survey auto-reportados. A correlação mais forte com Burnout_Level (codificado como 0–2) é a de Social_Isolation_Score (+0,044). Work_Life_Balance_Score apresenta correlação levemente negativa (−0,018), sugerindo que melhor equilíbrio vida-trabalho se associa a menos burnout. Horas semanais e idade têm correlações praticamente nulas.

C. Análise por subgrupos

A Figura 3 apresenta a distribuição do Burnout_Level segmentada pelas variáveis de regime de trabalho, gênero e setor. Os achados principais são:

- **Regime de trabalho:** trabalhadores em regime *remote* apresentam burnout médio de 1,33 (escala 0–2), superior ao regime híbrido (1,17) e presencial (0,96). O regime remoto associa-se, neste dataset, ao **maior** nível de esgotamento — achado contraintuitivo que reflete possivelmente maior isolamento social reportado por trabalhadores remotos;
- **Gênero:** as diferenças entre gêneros são pequenas (variação < 2 p.p. em burnout alto), sem subgrupo sistematicamente mais afetado;
- **Setor:** a prevalência de burnout alto varia entre setores, com *Customer Service* e *Manufacturing* entre os mais afetados.

TABLE II
COMPONENTES DO PIPELINE E RESPECTIVOS MÓDULOS.

Etapa	Módulo	Responsabilidade	Saídas
1	<code>src/eda.py</code>	Análise exploratória	5 gráficos em <code>reports/figures/</code>
2	<code>src/preprocessing.py</code>	Limpeza e transformação	CSVs processados + <code>.pkl</code>
3	<code>src/training.py</code>	Treinamento dos modelos	3 modelos em <code>models/</code>
4	<code>src/evaluation.py</code>	Avaliação e comparação	Tabelas + gráficos de resultado
5	<code>src/scoring.py</code>	Scoring individual	Função <code>predict_burnout()</code>

Fonte: elaborado pelos autores.




Fig. 1. Distribuição da variável alvo `Burnout_Level` (barras por categoria).
Fonte: elaborado pelos autores.





Fig. 2. Mapa de calor de correlação de Pearson entre variáveis numéricas.
Fonte: elaborado pelos autores.


V. ETAPA 2 — PRÉ-PROCESSAMENTO

A. Transformações aplicadas


O módulo `src/preprocessing.py` aplica oito transformações em sequência antes do ajuste de qualquer transformador estatís-



(a) Por regime de trabalho



(b) Por gênero



(c) Por setor (burnout alto)

Fig. 3. Distribuição do Burnout_Level segmentado por subgrupos.
Fonte: elaborado pelos autores.

tico:

- 1) **Remoção do alvo nulo:** nenhuma linha com Burnout_Level ausente foi encontrada no dataset.
- 2) **Encoding do alvo ordinal:** Burnout_Level é convertido para inteiro: Low→0, Medium→1, High→2. O *pipeline* de regressão é mantido, e o *score* é normalizado dividindo a predição bruta por 2, mapeando-o para [0, 1].
- 3) **Feature engineering — has_physical_issue:** a coluna Physical_Health_Issues contém texto multi-label (e.g. “Back Pain; Eye Strain”). Substitui-se por um indicador binário:

$$\text{has_physical_issue} = \begin{cases} 1 & \text{se a coluna não é nula} \\ 0 & \text{caso contrário} \end{cases} \quad (1)$$

O campo Survey_Date é descartado (todos os registros são de junho de 2025; sem variabilidade temporal).

- 4) **Tratamento de Mental_Health_Status:** os 799 NaN (25,3%) são preenchidos com a categoria “None” (ausência de diagnóstico reportado), antes do encoding por mapeamento direto.

- 5) **Encoding das categóricas:** variáveis com ordem natural (e.g. Work_Arrangement: Onsite→0, Hybrid→1, Remote→2; Salary_Range: \$40K–60K→0 a \$120K+→4) recebem encoding ordinal; variáveis nominais (Gender, Region, Industry, Job_Role) recebem *label encoding* por ordem alfabética.
- 6) **Divisão 80/20:** o *dataset* é particionado em 2.525 registros de treino (80%) e 632 de teste (20%), com *random_state*=42, antes do ajuste de qualquer transformador — prevenção de *data leakage* (Seção V-B).
- 7) **Imputação por mediana:** o SimpleImputer é ajustado exclusivamente no treino. Apenas Job_Role apresentou valores ausentes no conjunto de treino (mediana = 9,0 — IT Support).
- 8) **Normalização MinMaxScaler:** escala todas as *features* para [0, 1], ajustado apenas no treino.

Os transformadores ajustados (*imputer.pkl* e *scaler.pkl*) são persistidos em *models/* e reutilizados nas etapas de avaliação e *scoring*.

B. Prevenção de data leakage

Data leakage (vazamento de dados) ocorre quando informações do conjunto de teste influenciam o processo de treinamento, produzindo métricas de desempenho artificialmente otimistas. Em pré-processamento, o erro mais comum é ajustar o imputador ou o escalonador sobre o conjunto completo de dados antes da divisão treino/teste.

Neste trabalho, a prevenção de *leakage* é garantida pela seguinte ordem estrita de operações:

- 1) Dividir o *dataset* em treino e teste;
- 2) Ajustar (*fit*) o imputador **somente no treino**;
- 3) Aplicar (*transform*) o imputador ao treino e ao teste separadamente;
- 4) Ajustar o escalonador **somente no treino**;
- 5) Aplicar o escalonador ao treino e ao teste.

Se o imputador fosse ajustado sobre o conjunto completo, a mediana calculada incorporaria a distribuição dos dados de teste — que o modelo nunca deveria “ver” durante o treino. O mesmo vale para o escalonador: ajustá-lo no conjunto completo revelaria ao modelo os valores mínimo e máximo do teste, inflando artificialmente as métricas de avaliação.

VI. ETAPA 3 — MODELOS DE APRENDIZADO DE MÁQUINA

Três modelos de regressão são treinados em complexidade crescente (`src/training.py`). Essa estratégia segue o princípio da *navalha de Ockham* aplicada ao aprendizado de máquina: um modelo mais complexo só se justifica se superar o mais simples em desempenho mensurável.

A. Regressão Linear — baseline

A Regressão Linear estima a relação entre *features* e alvo por meio de uma combinação linear ponderada:

$$\hat{y} = w_1x_1 + w_2x_2 + \dots + w_px_p + b = \mathbf{w}^\top \mathbf{x} + b \quad (2)$$

Os parâmetros $\mathbf{w}$ (coeficientes) e b (intercepto) são estimados pelo método dos mínimos quadrados ordinários (OLS), que minimiza a soma dos quadrados dos resíduos:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \sum_{i=1}^n (y_i - \mathbf{w}^\top \mathbf{x}_i - b)^2 \quad (3)$$

A vantagem principal da Regressão Linear é a **interpretabilidade direta**: cada coeficiente w_j representa o efeito marginal da *feature* j sobre o alvo, mantidas constantes as demais. No contexto deste trabalho, o coeficiente de *Work_Arrangement* foi +0,364, o maior em valor absoluto — confirmando que o regime de trabalho é a variável de maior peso linear na predição do burnout ordinal. O modelo é usado como **piso de referência** (*baseline*) para comparação com abordagens mais complexas.

B. Random Forest

O Random Forest [4] é um método *ensemble* que constrói B árvores de decisão independentes e combina suas predições pela média:

$$\hat{y}_{\text{RF}} = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (4)$$

Cada árvore T_b é construída sobre uma amostra *bootstrap* do conjunto de treino e, em cada divisão de nó, considera apenas um subconjunto aleatório de $\sqrt{p}$ *features* (*feature bagging*). Esses dois mecanismos de aleatorização reduzem a correlação entre as árvores, diminuindo a variância do ensemble sem aumentar o viés.

A importância de cada *feature* é calculada automaticamente como a redução média de impureza (MSE, no caso de regressão) provocada por divisões naquela *feature* ao longo de todas as árvores. No *dataset* estudado, o Random Forest atribuiu a seguinte importância às *features*:

- Age: **16,5%**
- Hours_Per_Week: 15,3%
- Job_Role: 13,4%
- Industry: 9,1%
- Mental_Health_Status: 8,4%
- Region: 7,9%
- Social_Isolation_Score: 6,9%
- Salary_Range: 6,8%
- Work_Life_Balance_Score: 6,8%
- Work_Arrangement: 4,1%
- Gender: 3,5%
- has_physical_issue: 1,4%

A importância é distribuída entre as 12 *features*, com Age e Hours_Per_Week liderando — padrão esperado em dados de survey sem um preditor único dominante. Na configuração utilizada: `n_estimators=100`, `random_state=42`, `n_jobs=-1`.

C. XGBoost

O XGBoost (*Extreme Gradient Boosting*) [5] é um algoritmo de *gradient boosting* sequencial: ao contrário do Random Forest, que constrói árvores em paralelo e independentemente, o XGBoost constrói árvores de forma aditiva, onde cada nova árvore f_t é treinada para corrigir os erros residuais do modelo acumulado até a iteração anterior:

$$F_t(\mathbf{x}) = F_{t-1}(\mathbf{x}) + \eta \cdot f_t(\mathbf{x}) \quad (5)$$

O parâmetro η (`learning_rate`) controla a contribuição de cada nova árvore: valores pequenos tornam o aprendizado mais conservador e geralmente produzem melhor generalização, exigindo mais árvores (`n_estimators`) para atingir o mesmo nível de ajuste. A profundidade máxima das árvores (`max_depth`) regula a capacidade de capturar interações complexas entre *features*. A função objetivo inclui termos de regularização L_1 e L_2 que penalizam modelos com muitas folhas ou pesos muito grandes, contribuindo para a prevenção de *overfitting*.

TABLE III
ESPAÇO DE BUSCA DE HIPERPARÂMETROS DO XGBOOST.

Hiperparâmetro	Valores testados	Melhor valor
n_estimators	100, 200	100
max_depth	3, 5	3
learning_rate	0,05; 0,10; 0,20	0,05

Fonte: elaborado pelos autores.

TABLE IV
MÉTRICAS NO CONJUNTO DE TESTE ($n = 632$). ALVO ORDINAL: 0 = Low, 1 = Medium, 2 = High.

Modelo	MAE	RMSE	R ²
Regressão Linear	0,635	0,764	0,040
Random Forest	0,665	0,784	-0,011
XGBoost	0,640	0,766	0,036

Fonte: elaborado pelos autores.

Os hiperparâmetros são otimizados via GridSearchCV, que realiza busca exaustiva sobre todas as combinações do espaço definido na Tabela III, avaliando cada combinação com validação cruzada de 5 *folds* (12 combinações $\times$ 5 = **60 ajustes** no total). Os melhores hiperparâmetros encontrados foram: learning_rate=0,05, max_depth=3, n_estimators=100, com MSE médio de validação cruzada de 0,5386.

VII. ETAPA 4 — AVALIAÇÃO DOS MODELOS

A. Métricas de avaliação

Três métricas de regressão são calculadas para cada modelo:

- **MAE** (Erro Médio Absoluto): $MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$ — interpretável diretamente na escala do alvo (unidades da escala ordinal 0–2 do alvo);
- **RMSE** (Raiz do Erro Quadrático Médio): $RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$ — penaliza erros maiores de forma quadrática;
- **R²** (Coeficiente de Determinação): $R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$ — proporção da variância do alvo explicada pelo modelo (1,0 = ajuste perfeito).

B. Resultados no conjunto de teste

A Tabela IV apresenta as métricas calculadas sobre os 632 registros de teste — dados completamente isolados durante o treinamento. Os três modelos obtêm desempenho similar, reflexo das fracas correlações entre as *features* e o alvo nos dados de survey auto-reportados.

Os modelos apresentam R² baixos (máximo 0,040 para a Regressão Linear), o que é esperado em dados de survey auto-reportados onde as correlações entre *features* e alvo são fracas (máximo Pearson $\approx$ 0,044). O MAE de $\approx$ 0,64 corresponde a **menos de um terço do intervalo ordinal** (0–2), indicando que os modelos acertam aproximadamente a categoria central na maioria dos casos. O Random Forest obteve R² negativo, indicando ajuste pior do que a média simples — resultado que ressalta a complexidade do fenômeno.

C. Validação cruzada K-Fold

A validação cruzada K-Fold com $k = 5$ aplicada ao conjunto de treino verifica se os resultados são estáveis e independem da partição específica treino/teste utilizada (Tabela V).

A Regressão Linear apresenta o R² médio mais alto (0,021) e menor variabilidade entre *folds* (dp=0,021). O Random Forest obteve R² médio negativo (-0,028), confirmando sua limitação em dados com sinal preditivo fraco. Todos os modelos mostram baixa variância entre *folds*, indicando **ausência de overfitting** — porém também confirmando que a capacidade preditiva é globalmente modesta.

D. Dispersão real $\times$ predito

A Figura 4 apresenta os gráficos de dispersão entre valores reais e preditos. Dado o R² baixo, os três gráficos mostram dispersão considerável em torno da diagonal. Os modelos tendem a prever valores próximos da média (categoria Medium), refletindo a distribuição do alvo (43% Medium). Isso sugere que as *features* disponíveis no dataset não capturam plenamente os determinantes individuais do burnout.

E. Importância das features

A Figura 5 mostra que a importância é distribuída entre as *features*: no Random Forest, Age (16,5%) e Hours_Per_Week (15,3%) lideram, seguidos por Job_Role (13,4%). No XGBoost, Work_Arrangement domina (29,3%), refletindo o achado da EDA de que o regime de trabalho é o preditor mais forte.

VIII. ANÁLISE DE EQUIDADE

A análise de equidade verifica se os modelos apresentam erros sistematicamente maiores para determinados subgrupos demográficos — o que indicaria viés preditivo com potencial impacto discriminatório em decisões de RH. A Figura 6 e a Tabela VI mostra as diferenças de MAE entre subgrupos em todos os modelos.

Os MAEs por subgrupo são relativamente próximos entre si, sem disparidade sistemática gritante. O subgrupo “*Prefer not to say*” apresenta MAE ligeiramente superior (0,72–0,78), possivelmente por menor representatividade amostral. Trabalhadores em regime *remote* mostram MAE levemente inferior, coerente com o maior volume de registros nessa categoria (burnout médio mais alto = predições mais fáceis de acertar).

Ressalva: esta análise é uma verificação inicial baseada em comparação de MAE por grupo. Uma auditoria completa de equidade exigiria métricas formais de *fairness* como *equalized odds* ou *demographic parity*, que estão fora do escopo deste trabalho mas são recomendadas antes de qualquer uso em decisões que afetem trabalhadores.

IX. ETAPA 5 — PRODUTO FINAL: SISTEMA DE SCORING


A. Função predict_burnout

O módulo `src/scoring.py` expõe a função `predict_burnout(employee)`, que transforma um dicionário com os atributos brutos de um funcionário em escore de risco e classificação. A função carrega os artefatos (`imputer.pkl`, `scaler.pkl` e `xgboost_model.pkl`) do disco uma única vez por


TABLE V
VALIDAÇÃO CRUZADA K-FOLD ($k = 5$) NO CONJUNTO DE TREINO. M = MÉDIA; DP = DESVIO PADRÃO ENTRE *FOLDS*.

Modelo	MAE _m	MAE _{dp}	RMSE _m	RMSE _{dp}	R _m ²	R _{dp} ²
Reg. Linear	0,585	0,010	0,729	0,008	0,021	0,021
Random Forest	0,614	0,013	0,747	0,016	−0,028	0,041
XGBoost	0,596	0,009	0,733	0,009	0,008	0,027


Fonte: elaborado pelos autores.



(a) Regressão Linear



(b) Random Forest




(c) XGBoost — melhor ajuste

Fig. 4. Dispersão real $\times$ predito para os três modelos. A diagonal representa ajuste perfeito ($\hat{y} = y$).
Fonte: elaborado pelos autores.


TABLE VI
MAE POR SUBGRUPO DEMOGRÁFICO E REGIME DE TRABALHO.

Modelo	Female	Male	Non-bin.	Pref.	Hybrid	Onsite	Remote
Reg. Linear	0,638	0,627	0,662	0,781	0,652	0,632	0,616
Random Forest	0,669	0,664	0,589	0,686	0,697	0,668	0,609
XGBoost	0,647	0,632	0,630	0,720	0,649	0,643	0,620

Fonte: elaborado pelos autores.




(a) Random Forest




(b) XGBoost

Fig. 5. Importância relativa das *features* nos modelos de *ensemble*. *Age* e *Hours_Per_Week* lideram no Random Forest; *Work_Arrangement* domina no XGBoost (29,3%).

Fonte: elaborado pelos autores.



(a) MAE por gênero



(b) MAE por regime de trabalho

Fig. 6. Comparação de MAE por subgrupo nos três modelos.

Fonte: elaborado pelos autores.

TABLE VII
FAIXAS DE RISCO E AÇÕES RECOMENDADAS.

Score	Classificação	Ação recomendada
[0,0; 0,3]	Baixo	Nenhuma ação imediata
(0,3; 0,6]	Moderado	Atenção recomendada
[0,6; 1,0]	Alto	Intervenção necessária

Fonte: elaborado pelos autores.

processo (*cache*), minimizando latência em uso de produção. Internamente, aplica exatamente as mesmas transformações do treino:

- 1) Preenchimento de *Mental_Health_Status* ausente com "None";
- 2) Encoding das variáveis categóricas via *ENCODING_MAP*;
- 3) Cálculo de *has_physical_issue* (0 ou 1);
- 4) Imputação via *imputer.pkl* (mediana do treino);
- 5) Normalização via *scaler.pkl*;
- 6) Predição via *xgboost_model.pkl*;
- 7) Normalização do escore: $\text{score} = \text{clamp}(\hat{y}/2, 0, 1)$;
- 8) Classificação de risco (Tabela VII).

```
1 from src.scoring import predict_burnout
2
```

```
3 score, risco = predict_burnout({
4     "Age": 40,
5     "Gender": "Male",
6     "Region": "North America",
7     "Industry": "Finance",
8     "Job_Role": "Project Manager",
9     "Work_Arrangement": "Hybrid",
10    "Hours_Per_Week": 50,
11    "Mental_Health_Status": "Anxiety",
12    "Work_Life_Balance_Score": 3,
13    "has_physical_issue": 0,
14    "Social_Isolation_Score": 3,
15    "Salary_Range": "$60K-80K",
16 })
17 # Saída: score = 0.5630 | risco = 'moderado'
```

Listing 1. Uso programático de *predict_burnout* via *src/scoring.py*.

B. Script interativo — *prever.py*

Para uso operacional direto por profissionais de RH, o projeto inclui *prever.py* — um script de linha de comando interativo que dispensa qualquer conhecimento de programação. Ao executar `python prever.py`, o sistema solicita o preenchimento de campos estruturados sobre o funcionário avaliado:

- Nome do funcionário (apenas para exibição);

- Gênero (seleção numerada: Female, Male, Non-binary, Prefer not to say);
- Idade (18–70);
- Região geográfica (6 opções);
- Setor / indústria (9 opções);
- Cargo (20 opções);
- Regime de trabalho (Onsite, Hybrid, Remote);
- Horas trabalhadas por semana (35–65);
- Condição de saúde mental (7 opções + None);
- Equilíbrio vida-trabalho (1–5);
- Problemas físicos relatados (Sim/Não);
- Nível de isolamento social (1–5);
- Faixa salarial anual (\$40K–\$120K+).

Ao concluir a entrada, o sistema exibe o escore calculado com uma barra visual de risco e a orientação correspondente:

```

1 =====
2  RESULTADO - JOAO SILVA
3  =====
4  Score      : 0.5924  [##### ]
5  Risco      : MODERADO
6  Orientacao : Atencao recomendada. Acompanhar de perto.
7  =====

```

Listing 2. Exemplo de saída do `prever.py` para um caso de risco moderado.

Internamente, `prever.py` chama `predict_burnout()` do módulo de *scoring*, mantendo separação clara entre a camada de entrada/apresentação e a lógica de predição. Os casos de referência cobrem as três faixas: perfil *remote* com bom equilíbrio → score $\approx 0,71$ (alto — coerente com o achado da EDA de que trabalhadores remotos têm burnout médio maior); perfil híbrido moderado → score $\approx 0,56$ (moderado); perfil presencial com muitas horas e Burnout diagnosticado → score $\approx 0,41$ (moderado).

X. LIMITAÇÕES

- 1) **Dataset de survey auto-reportado.** O dataset “*Remote Work Health Impact Survey 2025*” reúne respostas voluntárias de um survey anônimo, sujeitas a viés de resposta e seleção amostral. As correlações entre *features* e alvo são fracas (máx. $\approx 0,044$), resultando em $R^2 \approx 0,04$ para todos os modelos — desempenho típico para dados de saúde ocupacional auto-reportados. As métricas devem ser interpretadas como desempenho em um *benchmark* de survey, não como expectativa de campo em dados de RH corporativos.
- 2) **Caráter preditivo, não diagnóstico.** O escore é um indicador estatístico de risco — não constitui diagnóstico de saúde mental e não substitui avaliação conduzida por profissional habilitado (psicólogo, médico do trabalho). O sistema deve ser usado exclusivamente como ferramenta de triagem e priorização.
- 3) **Análise de equidade superficial.** A comparação de MAE por grupo é uma verificação inicial; métricas formais de *fairness* (*equalized odds*, *demographic parity*) não foram aplicadas.
- 4) **Ausência de temporalidade.** Todos os registros do dataset foram coletados em junho de 2025. Sem vari-

abilidade temporal, o modelo não captura tendências sazonais nem mudanças no perfil de burnout ao longo do tempo.

XI. CONCLUSÃO

Este trabalho apresentou um *pipeline* modular, reproduzível e documentado para predição e classificação de risco de *burnout*, alinhado aos ODS 3, ODS 8 e ODS 10 da ONU e construído com código aberto em Python. As cinco etapas — EDA, pré-processamento, treinamento, avaliação e *scoring* — foram implementadas em módulos dedicados, testados automaticamente e com artefatos reproduzíveis via SEED = 42.

A comparação sistemática de três modelos mostrou desempenho similar entre eles ($R^2 \approx 0,04$), reflexo das fracas correlações presentes nos dados de survey auto-reportados. A Regressão Linear obteve o melhor R^2 (0,040) no conjunto de teste; o XGBoost, com MAE de 0,640, é utilizado na interface de *scoring* por sua robustez a não-linearidades. A análise de equidade não identificou viés preditivo sistemático por gênero ou regime de trabalho. O achado exploratório de maior impacto prático foi a associação entre regime *remote* e maior burnout médio (1,33 vs. 0,96 no regime presencial), sugerindo que o isolamento social pode ser um fator mediador relevante em contextos de trabalho remoto.

O produto final, `prever.py`, entrega o sistema como script interativo de terminal acessível a profissionais de RH sem conhecimento técnico, reforçando o caráter aplicado do trabalho. Como trabalhos futuros sugerem-se: validação com dados reais; auditoria formal de *fairness*; detecção de *drift* e re-treinamento periódico; e integração com sistemas corporativos de RH.

REFERÊNCIAS

- [1] MASLACH, Christina; JACKSON, Susan E. The measurement of experienced burnout. **Journal of Organizational Behavior**, [S.l.], v. 2, n. 2, p. 99–113, 1981.
- [2] SALVAGIONI, Denise Albieri Jodas et al. Physical, psychological and occupational consequences of job burnout: a systematic review of prospective studies. **PLOS ONE**, [S.l.], v. 12, n. 10, e0185781, 2017. Disponível em: <https://doi.org/10.1371/journal.pone.0185781>. Acesso em: jun. 2026.
- [3] ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). **Objetivos de Desenvolvimento Sustentável**. Nova York: ONU, 2015. Disponível em: <https://brasil.un.org/pt-br/sdgs>. Acesso em: jun. 2026.
- [4] BREIMAN, Leo. Random Forests. **Machine Learning**, [S.l.], v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://doi.org/10.1023/A:1010933404324>. Acesso em: jun. 2026.
- [5] CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: a scalable tree boosting system. In: **INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING**, 22., 2016, San Francisco. **Anais [...]**. New York: ACM, 2016. p. 785–794. Disponível em: <https://arxiv.org/abs/1603.02754>. Acesso em: jun. 2026.
- [6] PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, [S.l.], v. 12, p. 2825–2830, 2011. Disponível em: <https://scikit-learn.org>. Acesso em: jun. 2026.
- [7] XGBOOST DEVELOPERS. **XGBoost documentation**. [S.l.]: XGBoost, 2024. Disponível em: <https://xgboost.readthedocs.io>. Acesso em: jun. 2026.
- [8] PURI, Pratyush. **Remote Work Health Impact Survey 2025**. [S.l.]: Kaggle, 2025. Disponível em: <https://www.kaggle.com/datasets/pratyushpuri/remote-work-health-impact-survey-2025>. Acesso em: jun. 2026.