

Predição e Classificação de Risco de Burnout

Pipeline de Aprendizado de Máquina Aplicado à Gestão de Saúde Ocupacional

Breno Porto Pinheiro do Prado, RA 185196

Guilherme Bento Ramos, RA 185226

Universidade Federal de São Paulo — UNIFESP

São José dos Campos

2026

Abstract—O esgotamento profissional (*burnout*) é um problema relevante de saúde ocupacional, associado a impactos sobre bem-estar, produtividade, rotatividade e absenteísmo. Este trabalho apresenta um *pipeline* modular de aprendizado de máquina para estimar e classificar risco de *burnout*, com alinhamento aos Objetivos de Desenvolvimento Sustentável ODS 3, ODS 8 e ODS 10 da ONU. O estudo utiliza o *dataset* “Remote Work Health Impact Survey 2025” (Kaggle), composto por 3.157 registros coletados em junho de 2025. O sistema percorre cinco etapas: análise exploratória, pré-processamento com prevenção de vazamento de dados, treinamento comparativo de Regressão Linear, Random Forest e XGBoost, avaliação com validação cruzada K-Fold e análise de equidade, além de uma função de *scoring* individual. O alvo *Burnout_Level*, categórico ordinal com classes Low, Medium e High, é convertido para escala numérica 0–2 e tratado como regressão ordinal. A predição final é normalizada para um escore de risco em $[0, 1]$, sem interpretação como probabilidade calibrada. No conjunto de teste, a Regressão Linear obteve o melhor desempenho numérico (MAE=0,635; RMSE=0,764; $R^2=0,040$), enquanto o XGBoost apresentou resultado próximo (MAE=0,640; RMSE=0,766; $R^2=0,036$) e foi utilizado na interface de *scoring* implementada. Os resultados indicam baixo poder explicativo global, compatível com as fracas correlações observadas nos dados de survey auto-reportados. Na EDA, trabalhadores em regime *remote* apresentaram *burnout* médio superior ao regime presencial (1,33 vs. 0,96 na escala ordinal).

Index Terms—burnout, aprendizado de máquina, regressão, XGBoost, Random Forest, saúde ocupacional, *scoring* de risco, ODS

- **ODS 3 — Saúde e Bem-Estar:** promoção de ambientes de trabalho saudáveis e redução de agravos à saúde mental;
- **ODS 8 — Trabalho Decente e Crescimento Econômico:** apoio a condições de trabalho seguras, saudáveis e sustentáveis;
- **ODS 10 — Redução das Desigualdades:** identificação de diferenças entre subgrupos para orientar análises de equidade.

Técnicas de aprendizado de máquina podem apoiar a triagem de risco ao identificar padrões em dados estruturados sobre regime de trabalho, carga horária, saúde reportada, isolamento social e equilíbrio vida-trabalho. No entanto, o sistema proposto neste trabalho não deve ser interpretado como instrumento de diagnóstico clínico. O *pipeline* produz um escore normalizado de risco com base em padrões observados no conjunto de treino. A interpretação dos resultados e qualquer decisão sobre acompanhamento ou intervenção devem envolver profissionais habilitados e a equipe responsável pela gestão de pessoas.

Este trabalho desenvolve um *pipeline* modular, com código aberto e reproduzível via SEED = 42, que compara três modelos de regressão, avalia o erro por subgrupos e disponibiliza uma interface de *scoring* individual em terminal.

I. INTRODUÇÃO

O esgotamento profissional (*burnout*) é um fenômeno psicossocial de impacto crescente nas organizações contemporâneas. Definido por Maslach e Jackson [1] como síndrome de exaustão emocional, despersonalização e redução do senso de realização pessoal, o *burnout* foi reconhecido em 2019 pela Organização Mundial da Saúde (OMS) como fenômeno ocupacional na Classificação Internacional de Doenças (CID-11). Pesquisas de longo prazo associam o fenômeno a absenteísmo, intenção de abandono de cargo, doenças cardiovasculares e transtornos mentais [2].

Além do impacto individual, o *burnout* gera custos para organizações e para sistemas de saúde. Por esse motivo, o tema se relaciona aos seguintes Objetivos de Desenvolvimento Sustentável da ONU [3]:

II. DATASET

A. Descrição

O *dataset* “Remote Work Health Impact Survey 2025” [8], disponível publicamente na plataforma Kaggle, reúne respostas de um survey global aplicado em junho de 2025 a trabalhadores em regimes remoto, híbrido e presencial. O conjunto possui **3.157 registros** e **14 colunas** (Tabela I).

A variável alvo é *Burnout_Level*, categórica ordinal com três categorias: Low, Medium e High. Para o treinamento, as classes foram convertidas para 0, 1 e 2, respectivamente. A distribuição do alvo é: Low = 23,6%, Medium = 43,3% e High = 33,1%. Nenhum registro apresenta alvo ausente.

As únicas colunas com valores ausentes são *Mental_Health_Status* (799 registros, 25,3%) e *Physical_Health_Issues* (280 registros, 8,9%). A primeira é preenchida com a categoria None; a segunda é convertida em uma variável binária que indica se houve algum problema físico reportado.

TABLE I
VARIÁVEIS DO DATASET “REMOTE WORK HEALTH IMPACT SURVEY 2025”.

Coluna	Tipo	Faixa / Valores	Papel
Survey_Date	Data	Junho/2025	Descartada
Age	Num. inteira	22–65	Feature
Gender	Categ. nominal	Female, Male, Non-binary, ...	Feature
Region	Categ. nominal	6 regiões globais	Feature
Industry	Categ. nominal	9 setores	Feature
Job_Role	Categ. nominal	24 cargos	Feature
Work_Arrangement	Categ. ordinal	Onsite, Hybrid, Remote	Feature
Hours_Per_Week	Num. inteira	35–65	Feature
Mental_Health_Status	Categ. nominal	6 condições + None	Feature
Burnout_Level	Categ. ordinal	Low, Medium, High	Alvo
Work_Life_Balance_Score	Num. ordinal	1–5	Feature
Physical_Health_Issues	Texto multi-label	variável ou ausente	→ has_physical_issue
Social_Isolation_Score	Num. ordinal	1–5	Feature
Salary_Range	Categ. ordinal	\$40K–\$120K+	Feature

Fonte: elaborado pelos autores.

B. Natureza do conjunto de dados

Os dados são auto-reportados por meio de survey anônimo. Isso torna o conjunto útil para um estudo aplicado de aprendizado supervisionado, mas também impõe limitações: respostas podem conter viés de autopercepção, viés de seleção amostral e inconsistências típicas de questionários.

O campo `Survey_Date` é uniforme em junho de 2025 e foi descartado por não oferecer variação temporal útil para o modelo. Como o conjunto não contém dados longitudinais, o estudo não captura mudanças de risco ao longo do tempo.

III. ARQUITETURA DO PIPELINE

O sistema é estruturado como um *pipeline* sequencial de cinco etapas, cada uma implementada em um módulo Python dedicado (Tabela II). Essa separação facilita execução, teste e manutenção dos componentes.

O fluxo de dados segue a ordem das etapas: a EDA descreve o comportamento do conjunto; o pré-processamento produz os dados limpos e os artefatos de transformação (`imputer.pkl` e `scaler.pkl`); o treinamento gera os modelos serializados; a avaliação compara os modelos sobre o conjunto de teste e por validação cruzada; e o *scoring* reutiliza os artefatos de transformação com o modelo carregado pela interface.

A reprodutibilidade é controlada pelo parâmetro global `SEED = 42`, usado na divisão treino/teste, no Random Forest, no XGBoost e na validação cruzada. Nas mesmas condições de ambiente, dados e versões das bibliotecas, a execução do *pipeline* deve produzir resultados reprodutíveis.

IV. ETAPA 1 — ANÁLISE EXPLORATÓRIA DOS DADOS

A. Distribuição da variável alvo

O `Burnout_Level` é distribuído em três categorias: **Low** (23,6%), **Medium** (43,3%) e **High** (33,1%) (Figura 1). A concentração em *Medium* indica que a maior parte dos respondentes relatou nível intermediário de esgotamento.

B. Correlações entre variáveis numéricas

O mapa de calor de correlação de Pearson (Figura 2) mostra correlações fracas entre as variáveis numéricas e o alvo. A maior correlação com `Burnout_Level`, codificado




Fig. 1. Distribuição da variável alvo `Burnout_Level` (barras por categoria).

Fonte: elaborado pelos autores.




Fig. 2. Mapa de calor de correlação de Pearson entre variáveis numéricas.

Fonte: elaborado pelos autores.

como 0–2, é a de `Social_Isolation_Score` (+0,044). O `Work_Life_Balance_Score` apresenta correlação levemente negativa (−0,018), indicando associação fraca entre melhor equilíbrio vida-trabalho e menor burnout. Idade e horas semanais apresentam correlação próxima de zero.

TABLE II
COMPONENTES DO PIPELINE E RESPECTIVOS MÓDULOS.

Etapa	Módulo	Responsabilidade	Saídas
1	src/eda.py	Análise exploratória	5 gráficos em reports/figures/
2	src/preprocessing.py	Limpeza e transformação	CSVs processados + .pkl
3	src/training.py	Treinamento dos modelos	3 modelos em models/
4	src/evaluation.py	Avaliação e comparação	Tabelas + gráficos de resultado
5	src/scoring.py	Scoring individual	Função predict_burnout()

Fonte: elaborado pelos autores.

C. Análise por subgrupos

A Figura 3 apresenta a distribuição do Burnout_Level segmentada por regime de trabalho, gênero e setor. Os principais resultados observados são:

- **Regime de trabalho:** trabalhadores em regime *remote* apresentam burnout médio de 1,33 na escala 0–2, acima do regime híbrido (1,17) e presencial (0,96). Neste conjunto, o trabalho remoto se associa a maior nível médio de burnout;
- **Gênero:** as diferenças entre gêneros são pequenas (variação inferior a 2 p.p. em burnout alto), sem evidência de um subgrupo sistematicamente mais afetado;
- **Setor:** a prevalência de burnout alto varia entre setores, com *Customer Service* e *Manufacturing* entre os mais afetados.

V. ETAPA 2 — PRÉ-PROCESSAMENTO

A. Transformações aplicadas

O módulo `src/preprocessing.py` aplica as transformações abaixo antes do treinamento dos modelos, usando recursos da biblioteca scikit-learn [6]:

- 1) **Remoção do alvo nulo:** nenhuma linha com `Burnout_Level` ausente foi encontrada.
- 2) **Encoding do alvo ordinal:** `Burnout_Level` é convertido para inteiro: Low→0, Medium→1, High→2. O problema é tratado como regressão ordinal, e o escore de interface é calculado por $\hat{y}/2$, limitado ao intervalo [0, 1].
- 3) **Feature engineering** — `has_physical_issue`: a coluna `Physical_Health_Issues` contém texto multi-label, como “Back Pain; Eye Strain”. Ela é substituída pelo indicador binário:

$$h_{\text{físico}} = \begin{cases} 1, & \text{problema físico reportado} \\ 0, & \text{caso contrário} \end{cases} \quad (1)$$

- 4) **Remoção de colunas:** `Survey_Date` é descartada por ser uniforme em junho de 2025; `Physical_Health_Issues` é removida após a criação de `has_physical_issue`.
- 5) **Tratamento de Mental_Health_Status:** os 799 valores ausentes (25,3%) são preenchidos com a categoria `None`, interpretada como ausência de condição reportada.
- 6) **Encoding das categóricas:** variáveis com ordem natural recebem encoding ordinal, como `Work_Arrangement` (Onsite→0, Hybrid→1, Remote→2) e `Salary_Range`. Variáveis nominais, como `Gender`, `Region`, `Industry` e `Job_Role`, recebem mapeamento explícito por categoria.

- 7) **Divisão 80/20:** o conjunto é particionado em 2.525 registros de treino e 632 de teste, com `random_state=42`, antes do ajuste do imputador e do escalonador.
- 8) **Imputação por mediana:** o `SimpleImputer` é ajustado apenas no treino. Valores ausentes após o encoding são preenchidos com a mediana do conjunto de treino.
- 9) **Normalização MinMaxScaler:** todas as *features* são escalonadas para [0, 1], com ajuste feito apenas no treino. Os transformadores ajustados são salvos em `models/imputer.pkl` e `models/scaler.pkl`, sendo reutilizados na avaliação e no *scoring*.

B. Prevenção de data leakage

Data leakage ocorre quando informações do conjunto de teste influenciam o treinamento. Em pré-processamento, isso pode ocorrer quando o imputador ou o escalonador são ajustados sobre o conjunto completo antes da divisão treino/teste.

Neste trabalho, a prevenção de *leakage* segue a ordem abaixo:

- 1) Dividir o *dataset* em treino e teste;
- 2) Ajustar (*fit*) o imputador somente no treino;
- 3) Aplicar (*transform*) o imputador ao treino e ao teste;
- 4) Ajustar o escalonador somente no treino;
- 5) Aplicar o escalonador ao treino e ao teste.

Se o imputador fosse ajustado sobre todos os dados, a mediana incorporaria informação do conjunto de teste. O mesmo vale para o escalonador, que passaria a usar mínimos e máximos observados no teste. A ordem adotada evita esse vazamento.

VI. ETAPA 3 — MODELOS DE APRENDIZADO DE MÁQUINA

Três modelos de regressão são treinados em complexidade crescente: Regressão Linear, Random Forest e XGBoost. A comparação permite verificar se modelos mais flexíveis oferecem ganho mensurável em relação a um *baseline* simples.

A. Regressão Linear — baseline

A Regressão Linear estima o alvo por uma combinação linear das *features*:

$$\hat{y} = w_1x_1 + w_2x_2 + \dots + w_px_p + b = \mathbf{w}^T \mathbf{x} + b \quad (2)$$

Os parâmetros $\mathbf{w}$ e b são estimados pelo método dos mínimos quadrados ordinários (OLS), que minimiza a soma dos quadrados dos resíduos:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \sum_{i=1}^n (y_i - \mathbf{w}^\top \mathbf{x}_i - b)^2 \quad (3)$$

A principal vantagem da Regressão Linear é a interpretabilidade. Cada coeficiente representa a variação esperada no alvo para uma unidade de mudança na *feature*, mantendo as demais constantes. Neste trabalho, o coeficiente de maior magnitude foi o de *Work_Arrangement* ($w = +0,364$), indicando maior peso linear do regime de trabalho na predição ordinal.

B. Random Forest

O Random Forest [4] é um método *ensemble* que constrói B árvores de decisão e combina suas predições pela média:

$$\hat{y}_{\text{RF}} = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (4)$$

Cada árvore é treinada sobre uma amostra *bootstrap* do conjunto de treino e considera um subconjunto aleatório de *features* em cada divisão. Esses mecanismos reduzem a correlação entre árvores e tendem a diminuir a variância do modelo.

No conjunto estudado, o Random Forest distribuiu importância entre várias *features*, sem um único preditor dominante:

- Age: 16,5%

- Hours_Per_Week: 15,3%
- Job_Role: 13,4%
- Industry: 9,1%
- Mental_Health_Status: 8,4%
- Region: 7,9%
- Social_Isolation_Score: 6,9%
- Salary_Range: 6,8%
- Work_Life_Balance_Score: 6,8%
- Work_Arrangement: 4,1%
- Gender: 3,5%
- has_physical_issue: 1,4%


A configuração utilizada foi `n_estimators=100`, `random_state=42` e `n_jobs=-1`.

C. XGBoost


O XGBoost (*Extreme Gradient Boosting*) [5], [7] é um algoritmo de *gradient boosting* que constrói árvores de forma sequencial. Cada nova árvore é treinada para reduzir os resíduos do modelo acumulado até a iteração anterior:

$$F_t(\mathbf{x}) = F_{t-1}(\mathbf{x}) + \eta \cdot f_t(\mathbf{x}) \quad (5)$$


O parâmetro η (`learning_rate`) controla a contribuição de cada árvore. A profundidade máxima (`max_depth`) limita a complexidade das árvores e a capacidade de capturar interações. O



(a) Por regime de trabalho



(b) Por gênero



(c) Por setor (burnout alto)

Fig. 3. Distribuição do `Burnout_Level` segmentado por subgrupos.
Fonte: elaborado pelos autores.

modelo também inclui regularização, útil para reduzir risco de *overfitting*.

Os hiperparâmetros foram otimizados com GridSearchCV, avaliando 12 combinações com validação cruzada de 5 *folds*, totalizando 60 ajustes. Os melhores hiperparâmetros encontrados foram: `learning_rate=0,05`, `max_depth=3` e `n_estimators=100`, com MSE médio de validação cruzada de 0,5386.

TABLE III
ESPAÇO DE BUSCA DE HIPERPARÂMETROS DO XGBoost.

Hiperparâmetro	Valores testados	Melhor valor
<code>n_estimators</code>	100, 200	100
<code>max_depth</code>	3, 5	3
<code>learning_rate</code>	0,05; 0,10; 0,20	0,05

Fonte: elaborado pelos autores.

VII. ETAPA 4 — AVALIAÇÃO DOS MODELOS

A. Métricas de avaliação

Três métricas de regressão são calculadas para cada modelo:

- **MAE** (Erro Médio Absoluto): $MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$. É interpretável na escala ordinal 0–2 do alvo;
- **RMSE** (Raiz do Erro Quadrático Médio): $RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$. Penaliza erros maiores de forma quadrática;
- R^2 (Coeficiente de Determinação): $R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$. Mede a proporção da variância do alvo explicada pelo modelo.

B. Resultados no conjunto de teste

A Tabela IV apresenta as métricas calculadas sobre os 632 registros de teste, separados antes do ajuste dos transformadores. Os modelos tiveram MAE semelhante, mas baixo poder explicativo. A Regressão Linear obteve o melhor resultado no conjunto de teste, com maior R^2 e menor RMSE. O Random Forest apresentou R^2 negativo, indicando desempenho pior do que prever a média simples do alvo.

TABLE IV
MÉTRICAS NO CONJUNTO DE TESTE ($n = 632$). ALVO ORDINAL: 0 = Low, 1 = MEDIUM, 2 = High.

Modelo	MAE	RMSE	R^2
Regressão Linear	0,635	0,764	0,040
Random Forest	0,665	0,784	−0,011
XGBoost	0,640	0,766	0,036

Fonte: elaborado pelos autores.

O resultado indica que, para este conjunto de dados, o aumento de complexidade não trouxe ganho relevante em relação ao *baseline* linear. Isso é coerente com as correlações fracas observadas na EDA, em que a maior correlação numérica com o alvo foi de aproximadamente 0,044. Assim, a principal limitação não parece ser apenas a escolha do algoritmo, mas o baixo sinal preditivo das variáveis disponíveis.

C. Validação cruzada K-Fold

A validação cruzada K-Fold com $k = 5$, aplicada ao conjunto de treino, verifica a estabilidade dos resultados em diferentes partições (Tabela V). A Regressão Linear apresenta o melhor MAE médio, menor RMSE médio e maior R^2 médio. O XGBoost fica próximo no erro médio, mas não supera o *baseline* linear.

A baixa variação entre *folds* sugere estabilidade das métricas, mas não prova ausência completa de *overfitting*. A interpretação mais adequada é que os modelos são estáveis, porém limitados pelo baixo poder explicativo das *features* disponíveis.

D. Dispersão real versus predito

A Figura 4 apresenta os gráficos de dispersão entre valores reais e preditos. Como o R^2 é baixo, os pontos ficam dispersos em torno da diagonal. Os modelos tendem a prever valores próximos da média do alvo, especialmente da categoria *Medium*, que concentra 43,3% dos registros.


E. Importância das features

A Figura 5 mostra a importância relativa das *features* nos modelos de *ensemble*. No Random Forest, as maiores importâncias foram Age (16,5%), Hours_Per_Week (15,3%) e Job_Role (13,4%). No XGBoost, Work_Arrangement apresentou a maior importância relativa (29,3%), em concordância com o achado exploratório de diferenças de burnout médio por regime de trabalho.


TABLE V
VALIDAÇÃO CRUZADA K-FOLD ($k = 5$) NO CONJUNTO DE TREINO. M = MÉDIA; DP = DESVIO PADRÃO ENTRE *FOLDS*.

Modelo	MAE _m	MAE _{dp}	RMSE _m	RMSE _{dp}	R^2_m	R^2_{dp}
Reg. Linear	0,585	0,010	0,729	0,008	0,021	0,021
Random Forest	0,614	0,013	0,747	0,016	−0,028	0,041
XGBoost	0,596	0,009	0,733	0,009	0,008	0,027


Fonte: elaborado pelos autores.



(a) Regressão Linear




(b) Random Forest




(c) XGBoost — modelo usado no scoring

Fig. 4. Dispersão real $\times$ predito para os três modelos. A diagonal representa ajuste perfeito ($\hat{y} = y$).

Fonte: elaborado pelos autores.



(a) Random Forest



(b) XGBoost

Fig. 5. Importância relativa das *features* nos modelos de *ensemble*. No Random Forest, Age e Hours_Per_Week lideram; no XGBoost, Work_Arrangement apresenta a maior importância.

Fonte: elaborado pelos autores.

VIII. ANÁLISE DE EQUIDADE




Fig. 6. Comparação de MAE por gênero nos três modelos.
Fonte: elaborado pelos autores.

A análise de equidade verifica se os modelos apresentam erros sistematicamente maiores para determinados subgrupos. Neste trabalho, a comparação é feita por MAE entre grupos de gênero e regime de trabalho. As Figuras 6 e 7, juntamente com a Tabela VI, mostram os resultados.

Os valores de MAE por subgrupo são relativamente próximos. O subgrupo “Prefer not to say” apresenta erro maior na Regressão Linear e no XGBoost, o que pode estar associado à menor representatividade amostral. Por regime de trabalho, o grupo *remote* apresenta MAE ligeiramente menor nos três modelos.

Esta análise é inicial e não descarta viés preditivo. Uma auditoria de equidade mais completa exigiria métricas formais de *fairness*, como *equalized odds* e *demographic parity*, além de análise de representatividade dos grupos.

TABLE VI
MAE POR SUBGRUPO DEMOGRÁFICO E REGIME DE TRABALHO.

Modelo	Female	Male	Non-bin.	Pref.
Reg. Linear	0,638	0,627	0,662	0,781
Random Forest	0,669	0,664	0,589	0,686
XGBoost	0,647	0,632	0,630	0,720

Modelo	Hybrid	Onsite	Remote
Reg. Linear	0,652	0,632	0,616
Random Forest	0,697	0,668	0,609
XGBoost	0,649	0,643	0,620

Fonte: elaborado pelos autores.




Fig. 7. Comparação de MAE por regime de trabalho nos três modelos.
Fonte: elaborado pelos autores.

IX. ETAPA 5 — PRODUTO FINAL: SISTEMA DE SCORING

A. Função `predict_burnout`

O módulo `src/scoring.py` expõe a função `predict_burnout(employee)`, que recebe um dicionário com atributos

brutos de um funcionário e retorna um escore normalizado de risco e uma classificação. A implementação atual carrega os artefatos `imputer.pkl`, `scaler.pkl` e `xgboost_model.pkl`.

Essa escolha deve ser interpretada corretamente: pelos resultados da avaliação, a Regressão Linear obteve o melhor desempenho pontual no conjunto de teste quando se observa apenas R^2 e RMSE. O XGBoost, porém, apresentou desempenho muito próximo ao *baseline* linear e oferece maior capacidade de capturar relações não lineares e interações entre variáveis, característica útil para uma interface de *scoring* aplicada. Por esse motivo, ele foi mantido como modelo operacional do sistema.

Internamente, a função aplica as mesmas transformações usadas no treino:

- 1) Preenchimento de `Mental_Health_Status` ausente com `None`;
- 2) Encoding das variáveis categóricas via `ENCODING_MAP`;
- 3) Cálculo de `has_physical_issue`;
- 4) Imputação via `imputer.pkl`;
- 5) Normalização via `scaler.pkl`;
- 6) Predição via `xgboost_model.pkl`;
- 7) Normalização do escore: `score = clamp( $\hat{y}/2, 0, 1$ )`;
- 8) Classificação de risco conforme a Tabela VII.

TABLE VII
FAIXAS DE RISCO E AÇÕES RECOMENDADAS.

Score	Classificação	Ação recomendada
[0,0; 0,3]	Baixo	Acompanhar rotina normal
(0,3; 0,6]	Moderado	Atenção recomendada
[0,6; 1,0]	Alto	Encaminhar para avaliação profissional

Fonte: elaborado pelos autores.

```

1 from src.scoring import predict_burnout
2
3 score, risco = predict_burnout({
4     "Age": 40,
5     "Gender": "Male",
6     "Region": "North America",
7     "Industry": "Finance",
8     "Job_Role": "Project Manager",
9     "Work_Arrangement": "Hybrid",
10    "Hours_Per_Week": 50,
11    "Mental_Health_Status": "Anxiety",
12    "Work_Life_Balance_Score": 3,
13    "has_physical_issue": 0,
14    "Social_Isolation_Score": 3,
15    "Salary_Range": "$60K-80K",
16 })
17
18 # Saída: score = 0.5630 | risco = 'moderado'

```

Listing 1. Uso programático de `predict_burnout` via `src/scoring.py`.

B. Script interativo — `prever.py`

Para uso operacional, o projeto inclui `prever.py`, um script de linha de comando interativo. Ao executar `python prever.py`, o sistema solicita campos estruturados sobre o funcionário avaliado:

- Nome do funcionário, usado apenas para exibição;
- Gênero;
- Idade;

- Região geográfica;
- Setor ou indústria;
- Cargo;
- Regime de trabalho;
- Horas trabalhadas por semana;
- Condição de saúde mental reportada;
- Equilíbrio vida-trabalho;
- Problemas físicos relatados;
- Nível de isolamento social;
- Faixa salarial anual.

Ao concluir a entrada, o sistema exibe o escore calculado, a classificação de risco e a orientação correspondente:

```

1 =====
2
3 # RESULTADO - JOÃO SILVA
4
5 Score      : 0.5924 [#####          ]
6 Risco      : MODERADO
7 Orientação: Atenção recomendada. Acompanhar de perto.
8 =====

```

Listing 2. Exemplo de saída do `prever.py` para um caso de risco moderado.

O script chama `predict_burnout()` do módulo de *scoring*, mantendo separação entre entrada/apresentação e lógica de predição. Os casos de referência devem ser interpretados como demonstrações técnicas, não como validação clínica de risco.

X. LIMITAÇÕES

- 1) **Dados de survey auto-reportado.** O conjunto reúne respostas voluntárias, sujeitas a viés de resposta, viés de seleção e imprecisões de autopercepção. As métricas devem ser interpretadas como desempenho em um *benchmark* de survey, não como garantia de desempenho em dados reais de RH corporativo.
- 2) **Baixo sinal preditivo.** As correlações entre as *features* numéricas e o alvo são fracas. O melhor R^2 no conjunto de teste foi 0,040, e o Random Forest apresentou R^2 negativo. Isso indica que as variáveis disponíveis explicam apenas pequena parte da variação observada no alvo.
- 3) **Caráter preditivo, não diagnóstico.** O escore é uma pontuação estatística de risco. Ele não constitui diagnóstico de saúde mental e não substitui avaliação profissional.
- 4) **Possível circularidade em `Mental_Health_Status`.** A variável `Mental_Health_Status` contém a categoria `Burnout`. Embora ela seja uma condição reportada e não o alvo ordinal `Burnout_Level`, sua presença deve ser tratada com cautela. Em aplicações futuras, recomenda-se testar versões do modelo removendo ou recodificando essa categoria.
- 5) **Encoding de variáveis nominais.** Variáveis nominais como `Gender`, `Region`, `Industry` e `Job_Role` foram codificadas por mapeamento numérico. Esse procedimento simplifica o pipeline, mas pode introduzir relações ordinais artificiais. Alternativas como *one-hot encoding* devem ser avaliadas em versões futuras.

- 6) **Análise de equidade inicial.** A comparação de MAE por subgrupo é uma verificação preliminar. Métricas formais de *fairness* não foram aplicadas.
- 7) **Ausência de temporalidade.** Todos os registros foram coletados em junho de 2025. Sem dados longitudinais, o modelo não captura tendências sazonais nem mudanças no risco de burnout ao longo do tempo.
- 8) **Escolha operacional do XGBoost.** A Regressão Linear apresentou o melhor resultado pontual em algumas métricas, enquanto o XGBoost foi mantido no *scoring* por combinar desempenho próximo e maior flexibilidade para relações não lineares. Em versões futuras, essa escolha deve ser reavaliada com novos dados e validação externa.

XI. CONCLUSÃO

Este trabalho apresentou um *pipeline* modular e reproduzível para predição e classificação de risco de *burnout*, alinhado aos ODS 3, ODS 8 e ODS 10 da ONU. O sistema foi construído em Python e organizado em cinco etapas: análise exploratória, pré-processamento, treinamento, avaliação e *scoring*.

A comparação entre Regressão Linear, Random Forest e XGBoost mostrou que os três modelos apresentaram erro absoluto médio próximo, mas baixo poder explicativo. No conjunto de teste, a Regressão Linear obteve o melhor desempenho numérico, com MAE de 0,635, RMSE de 0,764 e R^2 de 0,040. O XGBoost apresentou desempenho próximo, com MAE de 0,640 e R^2 de 0,036, e foi o modelo carregado pela interface de *scoring* por sua flexibilidade para capturar relações não lineares. O Random Forest teve o pior resultado, com R^2 negativo.

Os resultados indicam que a principal limitação do estudo está no sinal preditivo disponível no conjunto de dados, não apenas na escolha do algoritmo. As *features* analisadas capturam parte limitada da variação do `Burnout_Level`. Mesmo assim, a EDA revelou diferenças relevantes entre subgrupos, especialmente a associação entre regime *remote* e maior burnout médio (1,33 vs. 0,96 no regime presencial).

O produto final, `prever.py`, disponibiliza uma interface de terminal para cálculo de escore de risco. Seu uso deve ser restrito à triagem estatística e ao apoio à priorização de acompanhamento, sem substituir avaliação profissional. Como trabalhos futuros, recomendam-se: comparar novamente a escolha operacional do modelo com novos dados; testar *one-hot encoding* para variáveis nominais; avaliar a remoção ou recodificação da categoria `Burnout` em `Mental_Health_Status`; aplicar auditoria formal de *fairness*; validar o sistema em dados reais de RH; e implementar monitoramento de *drift* com retreinamento periódico.

REFERÊNCIAS

- [1] MASLACH, Christina; JACKSON, Susan E. The measurement of experienced burnout. **Journal of Organizational Behavior**, [S.l.], v. 2, n. 2, p. 99–113, 1981.
- [2] SALVAGIONI, Denise Albieri Jodas et al. Physical, psychological and occupational consequences of job burnout: a systematic review of prospective studies. **PLOS ONE**, [S.l.], v. 12, n. 10, e0185781, 2017. Disponível em: <https://doi.org/10.1371/journal.pone.0185781>. Acesso em: jun. 2026.
- [3] ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). **Objetivos de Desenvolvimento Sustentável**. Nova York: ONU, 2015. Disponível em: <https://brasil.un.org/pt-br/sdgs>. Acesso em: jun. 2026.
- [4] BREIMAN, Leo. Random Forests. **Machine Learning**, [S.l.], v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://doi.org/10.1023/A:1010933404324>. Acesso em: jun. 2026.
- [5] CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: a scalable tree boosting system. In: **INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING**, 22., 2016, San Francisco. **Anais [...]**. New York: ACM, 2016. p. 785–794. Disponível em: <https://arxiv.org/abs/1603.02754>. Acesso em: jun. 2026.
- [6] PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, [S.l.], v. 12, p. 2825–2830, 2011. Disponível em: <https://scikit-learn.org>. Acesso em: jun. 2026.
- [7] XGBOOST DEVELOPERS. **XGBoost documentation**. [S.l.]: XGBoost, 2024. Disponível em: <https://xgboost.readthedocs.io>. Acesso em: jun. 2026.
- [8] PURI, Pratyush. **Remote Work Health Impact Survey 2025**. [S.l.]: Kaggle, 2025. Disponível em: <https://www.kaggle.com/datasets/pratyushpuri/remote-work-health-impact-survey-2025>. Acesso em: jun. 2026.