

Predição e Classificação de Risco de Burnout

Pipeline de Aprendizado de Máquina Aplicado à Gestão de Saúde Ocupacional

Breno Porto Pinheiro do Prado, RA 185196

Guilherme Bento Ramos, RA 185226

Universidade Federal de São Paulo — UNIFESP

São José dos Campos

2026

Abstract—O esgotamento profissional (*burnout*) é um problema relevante de saúde ocupacional, associado a impactos sobre bem-estar, produtividade, rotatividade e absenteísmo. Este trabalho apresenta um *pipeline* modular de aprendizado de máquina para estimar e classificar risco de *burnout*, com alinhamento aos Objetivos de Desenvolvimento Sustentável ODS 3, ODS 8 e ODS 10 da ONU. O estudo utiliza o *dataset* “Remote Work Health Impact Survey 2025” (Kaggle), composto por 3.157 registros coletados em junho de 2025. O sistema percorre cinco etapas: análise exploratória, pré-processamento com prevenção de vazamento de dados, treinamento comparativo de Regressão Linear, Random Forest e XGBoost, avaliação com validação cruzada K-Fold e análise de equidade, além de uma função de *scoring* individual. O alvo `Burnout_Level`, categórico ordinal com classes Low, Medium e High, é convertido para escala numérica 0–2 e tratado como regressão ordinal. A predição final é normalizada para um escore de risco em $[0, 1]$, sem interpretação como probabilidade calibrada. No conjunto de teste, a Regressão Linear obteve o melhor desempenho numérico (MAE=0,635; RMSE=0,764; $R^2=0,040$), enquanto o XGBoost apresentou resultado próximo (MAE=0,640; RMSE=0,766; $R^2=0,036$) e foi utilizado na interface de *scoring* implementada. Os resultados indicam baixo poder explicativo global, compatível com as fracas correlações observadas nos dados de survey auto-reportados. Na EDA, trabalhadores em regime *remote* apresentaram burnout médio superior ao regime presencial (1,33 vs. 0,96 na escala ordinal).

Index Terms—burnout, aprendizado de máquina, regressão, XGBoost, Random Forest, saúde ocupacional, *scoring* de risco, ODS

- **ODS 3 — Saúde e Bem-Estar:** promoção de ambientes de trabalho saudáveis e redução de agravos à saúde mental;
- **ODS 8 — Trabalho Decente e Crescimento Econômico:** apoio a condições de trabalho seguras, saudáveis e sustentáveis;
- **ODS 10 — Redução das Desigualdades:** identificação de diferenças entre subgrupos para orientar análises de equidade.

Técnicas de aprendizado de máquina podem apoiar a triagem de risco ao identificar padrões em dados estruturados sobre regime de trabalho, carga horária, saúde reportada, isolamento social e equilíbrio vida-trabalho. No entanto, o sistema proposto neste trabalho não deve ser interpretado como instrumento de diagnóstico clínico. O *pipeline* produz um escore normalizado de risco com base em padrões observados no conjunto de treino. A interpretação dos resultados e qualquer decisão sobre acompanhamento ou intervenção devem envolver profissionais habilitados e a equipe responsável pela gestão de pessoas.

Este trabalho desenvolve um *pipeline* modular, com código aberto e reprodutível via SEED,=,42, que compara três modelos de regressão, avalia o erro por subgrupos e disponibiliza uma interface de *scoring* individual em terminal.

II. DATASET

I. INTRODUÇÃO

O esgotamento profissional (*burnout*) é um fenômeno psicossocial de impacto crescente nas organizações contemporâneas. Definido por Maslach e Jackson [1] como síndrome de exaustão emocional, despersonalização e redução do senso de realização pessoal, o *burnout* foi reconhecido em 2019 pela Organização Mundial da Saúde (OMS) como fenômeno ocupacional na Classificação Internacional de Doenças (CID-11). Pesquisas de longo prazo associam o fenômeno a absenteísmo, intenção de abandono de cargo, doenças cardiovasculares e transtornos mentais [2].

Além do impacto individual, o burnout gera custos para organizações e para sistemas de saúde. Por esse motivo, o tema se relaciona aos seguintes Objetivos de Desenvolvimento Sustentável da ONU [3]:

A. Descrição

O *dataset* “Remote Work Health Impact Survey 2025” [8], disponível publicamente na plataforma Kaggle, reúne respostas de um survey global aplicado em junho de 2025 a trabalhadores em regimes remoto, híbrido e presencial. O conjunto possui **3.157 registros** e **14 colunas** (Tabela I).

A variável alvo é `Burnout_Level`, categórica ordinal com três categorias: Low, Medium e High. Para o treinamento, as classes foram convertidas para 0, 1 e 2, respectivamente. A distribuição do alvo é: Low = 23,6%, Medium = 43,3% e High = 33,1%. Nenhum registro apresenta alvo ausente.

As únicas colunas com valores ausentes são `Mental_Health_Status` (799 registros, 25,3%) e `Physical_Health_Issues` (280 registros, 8,9%). A primeira é preenchida com a categoria None; a segunda é convertida em uma variável binária que indica se houve algum problema físico reportado.

TABLE I
VARIÁVEIS DO DATASET “REMOTE WORK HEALTH IMPACT SURVEY 2025”.

Coluna	Tipo	Faixa / Valores	Papel
Survey_Date	Data	Junho/2025	Descartada
Age	Num. inteira	22–65	Feature
Gender	Categ. nominal	Female, Male, Non-binary, ...	Feature
Region	Categ. nominal	6 regiões globais	Feature
Industry	Categ. nominal	9 setores	Feature
Job_Role	Categ. nominal	24 cargos	Feature
Work_Arrangement	Categ. ordinal	Onsite, Hybrid, Remote	Feature
Hours_Per_Week	Num. inteira	35–65	Feature
Mental_Health_Status	Categ. nominal	6 condições + None	Feature
Burnout_Level	Categ. ordinal	Low, Medium, High	Alvo
Work_Life_Balance_Score	Num. ordinal	1–5	Feature
Physical_Health_Issues	Texto multi-label	var. ou ausente	→ has_physical_issue
Social_Isolation_Score	Num. ordinal	1–5	Feature
Salary_Range	Categ. ordinal	40K – –120K+	Feature

Fonte: elaborado pelos autores.

B. Natureza do conjunto de dados

Os dados são auto-reportados por meio de survey anônimo. Isso torna o conjunto útil para um estudo aplicado de aprendizado supervisionado, mas também impõe limitações: respostas podem conter vies de autopercepção, vies de seleção amostral e inconsistências típicas de questionários.

O campo `Survey_Date` é uniforme em junho de 2025 e foi descartado por não oferecer variação temporal útil para o modelo. Como o conjunto não contém dados longitudinais, o estudo não captura mudanças de risco ao longo do tempo.

III. ARQUITETURA DO PIPELINE

O sistema é estruturado como um *pipeline* sequencial de cinco etapas, cada uma implementada em um módulo Python dedicado (Tabela II). Essa separação facilita execução, teste e manutenção dos componentes.

O fluxo de dados segue a ordem das etapas: a EDA descreve o comportamento do conjunto; o pré-processamento produz os dados limpos e os artefatos de transformação (`imputer.pkl` e `scaler.pkl`); o treinamento gera os modelos serializados; a avaliação compara os modelos sobre o conjunto de teste e por validação cruzada; e o *scoring* reutiliza os artefatos de transformação com o modelo carregado pela interface.

A reprodutibilidade é controlada pelo parâmetro global `SEED`, =, 42, usado na divisão treino/teste, no Random Forest, no XGBoost e na validação cruzada. Nas mesmas condições de ambiente, dados e versões das bibliotecas, a execução do *pipeline* deve produzir resultados reprodutíveis.

IV. ETAPA 1 — ANÁLISE EXPLORATÓRIA DOS DADOS

A. Distribuição da variável alvo

O `Burnout_Level` é distribuído em três categorias: **Low** (23,6%), **Medium** (43,3%) e **High** (33,1%) (Figura 1). A concentração em *Medium* indica que a maior parte dos respondentes relatou nível intermediário de esgotamento.

B. Correlações entre variáveis numéricas

O mapa de calor de correlação de Pearson (Figura 2) mostra correlações fracas entre as variáveis numéricas e o alvo. A maior correlação com `Burnout_Level`, codificado como 0–2, é a de `Social_Isolation_Score` (+0,044). O `Work_Life_Balance_Score` apresenta correlação levemente negativa (−0,018), indicando associação fraca entre melhor equilíbrio vida-trabalho e menor burnout. Idade e horas semanais apresentam correlação próxima de zero.

C. Análise por subgrupos

A Figura 3 apresenta a distribuição do `Burnout_Level` segmentada por regime de trabalho, gênero e setor. Os principais resultados observados são:

- **Regime de trabalho:** trabalhadores em regime *remote* apresentam burnout médio de 1,33 na escala 0–2, acima do regime híbrido (1,17) e presencial (0,96). Neste conjunto, o trabalho remoto se associa a maior nível médio de burnout;
- **Gênero:** as diferenças entre gêneros são pequenas (variação inferior a 2 p.p. em burnout alto), sem evidência de um subgrupo sistematicamente mais afetado;
- **Setor:** a prevalência de burnout alto varia entre setores, com *Customer Service* e *Manufacturing* entre os mais afetados.

V. ETAPA 2 — PRÉ-PROCESSAMENTO

A. Transformações aplicadas

O módulo `src/preprocessing.py` aplica as transformações abaixo antes do treinamento dos modelos:

- 1) **Remoção do alvo nulo:** nenhuma linha com `Burnout_Level` ausente foi encontrada.
- 2) **Encoding do alvo ordinal:** `Burnout_Level` é convertido para inteiro: Low→0, Medium→1, High→2. O problema é tratado como regressão ordinal, e o escore de interface é calculado por $\hat{y}/2$, limitado ao intervalo [0, 1].

TABLE II
COMPONENTES DO PIPELINE E RESPECTIVOS MÓDULOS.

Etapa	Módulo	Responsabilidade	Saídas
1	src/eda.py	Análise exploratória	5 gráficos em reports/figures/
2	src/preprocessing.py	Limpeza e transformação	CSVs processados + .pkl
3	src/training.py	Treinamento dos modelos	3 modelos em models/
4	src/evaluation.py	Avaliação e comparação	Tabelas + gráficos de resultado
5	src/scoring.py	Scoring individual	Função predict_burnout()

Fonte: elaborado pelos autores.




Fig. 1. Distribuição da variável alvo Burnout_Level (barras por categoria).
Fonte: elaborado pelos autores.






Fig. 2. Mapa de calor de correlação de Pearson entre variáveis numéricas.
Fonte: elaborado pelos autores.

3) **Feature engineering** — has_physical_issue: a coluna Physical_Health_Issues contém texto multi-label, como


“Back Pain; Eye Strain”. Ela é substituída pelo indicador



(a) Por regime de trabalho



(b) Por gênero



(c) Por setor (burnout alto)

Fig. 3. Distribuição do Burnout_Level segmentado por subgrupos.
Fonte: elaborado pelos autores.

binário:

$$\text{has_physical_issue} = \begin{cases} 1 & \text{se há problema físico reportado} \\ 0 & \text{caso contrário} \end{cases} \quad (1)$$

- 4) **Remoção de colunas:** Survey_Date é descartada por ser uniforme em junho de 2025; Physical_Health_Issues é removida após a criação de has_physical_issue.
- 5) **Tratamento de Mental_Health_Status:** os 799 valores ausentes (25,3%) são preenchidos com a categoria None, interpretada como ausência de condição reportada.
- 6) **Encoding das categóricas:** variáveis com ordem natural recebem encoding ordinal, como Work_Arrangement (Onsite→0, Hybrid→1, Remote→2) e Salary_Range. Variáveis nominais, como Gender, Region, Industry e Job_Role, recebem mapeamento explícito por categoria.
- 7) **Divisão 80/20:** o conjunto é particionado em 2.525 registros de treino e 632 de teste, com random_state=42, antes do ajuste do imputador e do escalonador.
- 8) **Imputação por mediana:** o SimpleImputer é ajustado apenas no treino. Valores ausentes após o encoding são preenchidos com a mediana do conjunto de treino.

- 9) **Normalização MinMaxScaler:** todas as *features* são escalonadas para [0, 1], com ajuste feito apenas no treino. Os transformadores ajustados são salvos em models/imputer.pkl e models/scaler.pkl, sendo reutilizados na avaliação e no *scoring*.

B. Prevenção de data leakage

Data leakage ocorre quando informações do conjunto de teste influenciam o treinamento. Em pré-processamento, isso pode ocorrer quando o imputador ou o escalonador são ajustados sobre o conjunto completo antes da divisão treino/teste.

Neste trabalho, a prevenção de *leakage* segue a ordem abaixo:

- 1) Dividir o *dataset* em treino e teste;
- 2) Ajustar (*fit*) o imputador somente no treino;
- 3) Aplicar (*transform*) o imputador ao treino e ao teste;
- 4) Ajustar o escalonador somente no treino;
- 5) Aplicar o escalonador ao treino e ao teste.

Se o imputador fosse ajustado sobre todos os dados, a mediana incorporaria informação do conjunto de teste. O mesmo vale para o escalonador, que passaria a usar mínimos

e máximos observados no teste. A ordem adotada evita esse vazamento.

VI. ETAPA 3 — MODELOS DE APRENDIZADO DE MÁQUINA

Três modelos de regressão são treinados em complexidade crescente: Regressão Linear, Random Forest e XGBoost. A comparação permite verificar se modelos mais flexíveis oferecem ganho mensurável em relação a um *baseline* simples.

A. Regressão Linear — baseline

A Regressão Linear estima o alvo por uma combinação linear das *features*:

$$\hat{y} = w_1x_1 + w_2x_2 + \dots + w_px_p + b = \mathbf{w}^T \mathbf{x} + b \quad (2)$$

Os parâmetros $\mathbf{w}$ e b são estimados pelo método dos mínimos quadrados ordinários (OLS), que minimiza a soma dos quadrados dos resíduos:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \sum_{i=1}^n (y_i - \mathbf{w}^T \mathbf{x}_i - b)^2 \quad (3)$$

A principal vantagem da Regressão Linear é a interpretabilidade. Cada coeficiente representa a variação esperada no alvo para uma unidade de mudança na *feature*, mantendo as demais constantes. Neste trabalho, o coeficiente de maior magnitude foi o de *Work_Arrangement* ($w = +0,364$), indicando maior peso linear do regime de trabalho na predição ordinal.

B. Random Forest

O Random Forest [4] é um método *ensemble* que constrói B árvores de decisão e combina suas predições pela média:

$$\hat{y}_{\text{RF}} = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (4)$$

Cada árvore é treinada sobre uma amostra *bootstrap* do conjunto de treino e considera um subconjunto aleatório de *features* em cada divisão. Esses mecanismos reduzem a correlação entre árvores e tendem a diminuir a variância do modelo.

No conjunto estudado, o Random Forest distribuiu importância entre várias *features*, sem um único preditor dominante:

- Age: 16,5%
- Hours_Per_Week: 15,3%
- Job_Role: 13,4%
- Industry: 9,1%
- Mental_Health_Status: 8,4%
- Region: 7,9%
- Social_Isolation_Score: 6,9%
- Salary_Range: 6,8%
- Work_Life_Balance_Score: 6,8%
- Work_Arrangement: 4,1%
- Gender: 3,5%
- has_physical_issue: 1,4%

A configuração utilizada foi `n_estimators=100`, `random_state=42` e `n_jobs=-1`.

TABLE III
ESPAÇO DE BUSCA DE HIPERPARÂMETROS DO XGBOOST.

Hiperparâmetro	Valores testados	Melhor valor
<code>n_estimators</code>	100, 200	100
<code>max_depth</code>	3, 5	3
<code>learning_rate</code>	0,05; 0,10; 0,20	0,05

Fonte: elaborado pelos autores.

C. XGBoost

O XGBoost (*Extreme Gradient Boosting*) [5] é um algoritmo de *gradient boosting* que constrói árvores de forma sequencial. Cada nova árvore é treinada para reduzir os resíduos do modelo acumulado até a iteração anterior:

$$F_t(\mathbf{x}) = F_{t-1}(\mathbf{x}) + \eta \cdot f_t(\mathbf{x}) \quad (5)$$

O parâmetro η (`learning_rate`) controla a contribuição de cada árvore. A profundidade máxima (`max_depth`) limita a complexidade das árvores e a capacidade de capturar interações. O modelo também inclui regularização, útil para reduzir risco de *overfitting*.

Os hiperparâmetros foram otimizados com `GridSearchCV`, avaliando 12 combinações com validação cruzada de 5 *folds*, totalizando 60 ajustes. Os melhores hiperparâmetros encontrados foram: `learning_rate=0,05`, `max_depth=3` e `n_estimators=100`, com MSE médio de validação cruzada de 0,5386.

VII. ETAPA 4 — AVALIAÇÃO DOS MODELOS

A. Métricas de avaliação

Três métricas de regressão são calculadas para cada modelo:

- **MAE** (Erro Médio Absoluto): $\text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i|$. É interpretável na escala ordinal 0–2 do alvo;
- **RMSE** (Raiz do Erro Quadrático Médio): $\text{RMSE} = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$. Penaliza erros maiores de forma quadrática;
- **R²** (Coeficiente de Determinação): $R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$. Mede a proporção da variância do alvo explicada pelo modelo.

B. Resultados no conjunto de teste

A Tabela IV apresenta as métricas calculadas sobre os 632 registros de teste, separados antes do ajuste dos transformadores. Os modelos tiveram MAE semelhante, mas baixo poder explicativo. A Regressão Linear obteve o melhor resultado no conjunto de teste, com maior R² e menor RMSE. O Random Forest apresentou R² negativo, indicando desempenho pior do que prever a média simples do alvo.

O resultado indica que, para este conjunto de dados, o aumento de complexidade não trouxe ganho relevante em relação ao *baseline* linear. Isso é coerente com as correlações fracas observadas na EDA, em que a maior correlação numérica com o alvo foi de aproximadamente 0,044. Assim, a principal limitação não parece ser apenas a escolha do algoritmo, mas o baixo sinal preditivo das variáveis disponíveis.

TABLE IV
MÉTRICAS NO CONJUNTO DE TESTE ($n = 632$). ALVO ORDINAL: 0,=,Low, 1,=,MEDIUM, 2,=,High.

Modelo	MAE	RMSE	R ²
Regressão Linear	0,635	0,764	0,040
Random Forest	0,665	0,784	-0,011
XGBoost	0,640	0,766	0,036

Fonte: elaborado pelos autores.

C. Validação cruzada K-Fold

A validação cruzada K-Fold com $k = 5$, aplicada ao conjunto de treino, verifica a estabilidade dos resultados em diferentes partições (Tabela V). A Regressão Linear apresenta o melhor MAE médio, menor RMSE médio e maior R² médio. O XGBoost fica próximo no erro médio, mas não supera o *baseline* linear.

A baixa variação entre *folds* sugere estabilidade das métricas, mas não prova ausência completa de *overfitting*. A interpretação mais adequada é que os modelos são estáveis, porém limitados pelo baixo poder explicativo das *features* disponíveis.

D. Dispersão real $\times$ predito

A Figura 4 apresenta os gráficos de dispersão entre valores reais e preditos. Como o R² é baixo, os pontos ficam dispersos em torno da diagonal. Os modelos tendem a prever valores próximos da média do alvo, especialmente da categoria *Medium*, que concentra 43,3% dos registros.

E. Importância das features

A Figura 5 mostra a importância relativa das *features* nos modelos de *ensemble*. No Random Forest, as maiores importâncias foram Age (16,5%), Hours_Per_Week (15,3%) e Job_Role (13,4%). No XGBoost, Work_Arrangement apresentou a maior importância relativa (29,3%), em concordância com o achado exploratório de diferenças de burnout médio por regime de trabalho.

VIII. ANÁLISE DE EQUIDADE

A análise de equidade verifica se os modelos apresentam erros sistematicamente maiores para determinados subgrupos. Neste trabalho, a comparação é feita por MAE entre grupos de gênero e regime de trabalho. A Figura 6 e a Tabela VI mostram os resultados.

Os valores de MAE por subgrupo são relativamente próximos. O subgrupo “*Prefer not to say*” apresenta erro maior na Regressão Linear e no XGBoost, o que pode estar associado à menor representatividade amostral. Por regime de trabalho, o grupo *remote* apresenta MAE ligeiramente menor nos três modelos.

Esta análise é inicial e não descarta viés preditivo. Uma auditoria de equidade mais completa exigiria métricas formais de *fairness*, como *equalized odds* e *demographic parity*, além de análise de representatividade dos grupos.

IX. ETAPA 5 — PRODUTO FINAL: SISTEMA DE SCORING

A. Função *predict_burnout*

O módulo `src/scoring.py` expõe a função `predict_burnout(employee)`, que recebe um dicionário com atributos brutos de um funcionário e retorna um escore normalizado de risco e uma classificação. A implementação atual carrega os artefatos `imputer.pkl`, `scaler.pkl` e `xgboost_model.pkl`.

Essa escolha deve ser interpretada corretamente: pelos resultados da avaliação, a Regressão Linear é o modelo recomendado quando o critério é maior R² e menor RMSE no conjunto de teste. O XGBoost permanece como modelo da interface implementada por ser o artefato atualmente carregado pelo módulo de *scoring* e por apresentar desempenho próximo ao *baseline*. Em uma versão futura, recomenda-se alinhar a interface ao modelo recomendado pelas métricas ou justificar explicitamente a escolha do XGBoost como decisão de produto.

Internamente, a função aplica as mesmas transformações usadas no treino:

- 1) Preenchimento de `Mental_Health_Status` ausente com `None`;
- 2) Encoding das variáveis categóricas via `ENCODING_MAP`;
- 3) Cálculo de `has_physical_issue`;
- 4) Imputação via `imputer.pkl`;
- 5) Normalização via `scaler.pkl`;
- 6) Predição via `xgboost_model.pkl`;
- 7) Normalização do escore: `score = clamp( $\hat{y}/2$ ; 0; 1)`;
- 8) Classificação de risco conforme a Tabela VII.

```

1 from src.scoring import predict_burnout
2
3 score, risco = predict_burnout({
4     "Age": 40,
5     "Gender": "Male",
6     "Region": "North America",
7     "Industry": "Finance",
8     "Job_Role": "Project Manager",
9     "Work_Arrangement": "Hybrid",
10    "Hours_Per_Week": 50,
11    "Mental_Health_Status": "Anxiety",
12    "Work_Life_Balance_Score": 3,
13    "has_physical_issue": 0,
14    "Social_Isolation_Score": 3,
15    "Salary_Range": "$60K-80K",
16 })
17
18 # Saída: score = 0.5630 | risco = 'moderado'

```

Listing 1. Uso programático de `predict_burnout` via `src/scoring.py`.

B. Script interativo — *prever.py*


Para uso operacional, o projeto inclui `prever.py`, um script de linha de comando interativo. Ao executar `python prever.py`, o sistema solicita campos estruturados sobre o funcionário avaliado:

- Nome do funcionário, usado apenas para exibição;
- Gênero;
- Idade;
- Região geográfica;
- Setor ou indústria;


TABLE V
VALIDAÇÃO CRUZADA K-FOLD ($k = 5$) NO CONJUNTO DE TREINO. M,=,MÉDIA; DP,=,DESVIO PADRÃO ENTRE *FOLDS*.

Modelo	MAE _m	MAE _{dp}	RMSE _m	RMSE _{dp}	R _m ²	R _{dp} ²
Reg. Linear	0,585	0,010	0,729	0,008	0,021	0,021
Random Forest	0,614	0,013	0,747	0,016	-0,028	0,041
XGBoost	0,596	0,009	0,733	0,009	0,008	0,027


Fonte: elaborado pelos autores.



(a) Regressão Linear



(b) Random Forest




(c) XGBoost — modelo usado no scoring

Fig. 4. Dispersão real $\times$ predito para os três modelos. A diagonal representa ajuste perfeito ($\hat{y} = y$).
Fonte: elaborado pelos autores.


TABLE VI
MAE POR SUBGRUPO DEMOGRÁFICO E REGIME DE TRABALHO.

Modelo	Female	Male	Non-bin.	Pref.	Hybrid	Onsite	Remote
Reg. Linear	0,638	0,627	0,662	0,781	0,652	0,632	0,616
Random Forest	0,669	0,664	0,589	0,686	0,697	0,668	0,609
XGBoost	0,647	0,632	0,630	0,720	0,649	0,643	0,620

Fonte: elaborado pelos autores.




(a) Random Forest




(b) XGBoost

Fig. 5. Importância relativa das *features* nos modelos de *ensemble*. No Random Forest, Age e Hours_Per_Week lideram; no XGBoost, Work_Arrangement apresenta a maior importância.

Fonte: elaborado pelos autores.



(a) MAE por gênero



(b) MAE por regime de trabalho

Fig. 6. Comparação de MAE por subgrupo nos três modelos.

Fonte: elaborado pelos autores.

TABLE VII
FAIXAS DE RISCO E AÇÕES RECOMENDADAS.

Score	Classificação	Ação recomendada
[0,0; 0,3]	Baixo	Acompanhar rotina normal
(0,3; 0,6]	Moderado	Atenção recomendada
[0,6; 1,0]	Alto	Encaminhar para avaliação profissional

Fonte: elaborado pelos autores.

- Cargo;
- Regime de trabalho;
- Horas trabalhadas por semana;
- Condição de saúde mental reportada;
- Equilíbrio vida-trabalho;
- Problemas físicos relatados;
- Nível de isolamento social;
- Faixa salarial anual.

Ao concluir a entrada, o sistema exibe o escore calculado, a classificação de risco e a orientação correspondente:

```

1 =====
2
3 # RESULTADO - JOAO SILVA
4

```

```

5 Score : 0.5924 [#####]
6 Risco : MODERADO
7 Orientacao: Atencao recomendada. Acompanhar de perto.
8 =====

```

Listing 2. Exemplo de saída do `prever.py` para um caso de risco moderado.

O script chama `predict_burnout()` do módulo de *scoring*, mantendo separação entre entrada/apresentação e lógica de predição. Os casos de referência devem ser interpretados como demonstrações técnicas, não como validação clínica de risco.

X. LIMITAÇÕES

- 1) **Dados de survey auto-reportado.** O conjunto reúne respostas voluntárias, sujeitas a viés de resposta, viés de seleção e imprecisões de autopercepção. As métricas devem ser interpretadas como desempenho em um *benchmark* de survey, não como garantia de desempenho em dados reais de RH corporativo.
- 2) **Baixo sinal preditivo.** As correlações entre as *features* numéricas e o alvo são fracas. O melhor R^2 no conjunto de teste foi 0,040, e o Random Forest apresentou R^2 negativo. Isso indica que as variáveis disponíveis explicam apenas pequena parte da variação observada no alvo.

- 3) **Caráter preditivo, não diagnóstico.** O escore é uma pontuação estatística de risco. Ele não constitui diagnóstico de saúde mental e não substitui avaliação profissional.
- 4) **Possível circularidade em `Mental_Health_Status`.** A variável `Mental_Health_Status` contém a categoria `Burnout`. Embora ela seja uma condição reportada e não o alvo ordinal `Burnout_Level`, sua presença deve ser tratada com cautela. Em aplicações futuras, recomenda-se testar versões do modelo removendo ou recodificando essa categoria.
- 5) **Encoding de variáveis nominais.** Variáveis nominais como `Gender`, `Region`, `Industry` e `Job_Role` foram codificadas por mapeamento numérico. Esse procedimento simplifica o pipeline, mas pode introduzir relações ordinais artificiais. Alternativas como *one-hot encoding* devem ser avaliadas em versões futuras.
- 6) **Análise de equidade inicial.** A comparação de MAE por subgrupo é uma verificação preliminar. Métricas formais de *fairness* não foram aplicadas.
- 7) **Ausência de temporalidade.** Todos os registros foram coletados em junho de 2025. Sem dados longitudinais, o modelo não captura tendências sazonais nem mudanças no risco de burnout ao longo do tempo.
- 8) **Alinhamento entre avaliação e scoring.** A avaliação aponta a Regressão Linear como modelo recomendado por desempenho no teste, enquanto a interface atual utiliza XGBoost. Essa diferença deve ser corrigida ou justificada em versões futuras.

trabalhos futuros, recomendam-se: alinhar o modelo da interface ao modelo recomendado pela avaliação; testar *one-hot encoding* para variáveis nominais; avaliar a remoção ou recodificação da categoria `Burnout` em `Mental_Health_Status`; aplicar auditoria formal de *fairness*; validar o sistema em dados reais de RH; e implementar monitoramento de *drift* com retreinamento periódico.

XI. CONCLUSÃO

Este trabalho apresentou um *pipeline* modular e reproduzível para predição e classificação de risco de *burnout*, alinhado aos ODS 3, ODS 8 e ODS 10 da ONU. O sistema foi construído em Python e organizado em cinco etapas: análise exploratória, pré-processamento, treinamento, avaliação e *scoring*.

A comparação entre Regressão Linear, Random Forest e XGBoost mostrou que os três modelos apresentaram erro absoluto médio próximo, mas baixo poder explicativo. No conjunto de teste, a Regressão Linear obteve o melhor desempenho numérico, com MAE de 0,635, RMSE de 0,764 e R^2 de 0,040. O XGBoost apresentou desempenho próximo, com MAE de 0,640 e R^2 de 0,036, e foi o modelo carregado pela interface de *scoring*. O Random Forest teve o pior resultado, com R^2 negativo.

Os resultados indicam que a principal limitação do estudo está no sinal preditivo disponível no conjunto de dados, não apenas na escolha do algoritmo. As *features* analisadas capturam parte limitada da variação do `Burnout_Level`. Mesmo assim, a EDA revelou diferenças relevantes entre subgrupos, especialmente a associação entre regime *remote* e maior burnout médio (1,33 vs. 0,96 no regime presencial).

O produto final, `prever.py`, disponibiliza uma interface de terminal para cálculo de escore de risco. Seu uso deve ser restrito à triagem estatística e ao apoio à priorização de acompanhamento, sem substituir avaliação profissional. Como

REFERÊNCIAS

- [1] MASLACH, Christina; JACKSON, Susan E. The measurement of experienced burnout. **Journal of Organizational Behavior**, [S.l.], v. 2, n. 2, p. 99–113, 1981.
- [2] SALVAGIONI, Denise Albieri Jodas et al. Physical, psychological and occupational consequences of job burnout: a systematic review of prospective studies. **PLOS ONE**, [S.l.], v. 12, n. 10, e0185781, 2017. Disponível em: <https://doi.org/10.1371/journal.pone.0185781>. Acesso em: jun. 2026.
- [3] ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). **Objetivos de Desenvolvimento Sustentável**. Nova York: ONU, 2015. Disponível em: <https://brasil.un.org/pt-br/sdgs>. Acesso em: jun. 2026.
- [4] BREIMAN, Leo. Random Forests. **Machine Learning**, [S.l.], v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://doi.org/10.1023/A:1010933404324>. Acesso em: jun. 2026.
- [5] CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: a scalable tree boosting system. In: **INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING**, 22., 2016, San Francisco. **Anais [...]**. New York: ACM, 2016. p. 785–794. Disponível em: <https://arxiv.org/abs/1603.02754>. Acesso em: jun. 2026.
- [6] PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, [S.l.], v. 12, p. 2825–2830, 2011. Disponível em: <https://scikit-learn.org>. Acesso em: jun. 2026.
- [7] XGBOOST DEVELOPERS. **XGBoost documentation**. [S.l.]: XGBoost, 2024. Disponível em: <https://xgboost.readthedocs.io>. Acesso em: jun. 2026.
- [8] PURI, Pratyush. **Remote Work Health Impact Survey 2025**. [S.l.]: Kaggle, 2025. Disponível em: <https://www.kaggle.com/datasets/pratyushpuri/remote-work-health-impact-survey-2025>. Acesso em: jun. 2026.